# Rapport de projet

# **Introduction:**

L'objectif principal de ce projet est de mettre en place un système de recommandation d'image pour un utilisateur à partir des choix de ce dernier. Il est de plus dans notre mission d'apporter une représentation graphique des préférences des différents utilisateurs ainsi que la répartition des tags des images constituants notre base de données. Il est important de noter que cette base de données est constituée exclusivement d'images libres de droit issues de la plateforme Wikidata.

# I. Collecte et étiquetage des données:

## a. Récupération des images

Le processus de récupération des images est entièrement automatisé à l'exception d'une saisie de 2 paramètres par un utilisateur pour une raison que nous expliciterons ultérieurement.

Dès qu'une requête de recherche liée à un thème est effectuée sur le site Wikimedia commons, la bibliothèque BeautifulSoup permet de récupérer les liens de chaque image listée. Le téléchargement de ces images se fait alors automatiquement et ces dernières sont stockées dans un répertoire sur le terminal de l'utilisateur. Pour faciliter l'analyse des dites images, seules celles aux formats JPG et JPEG sont conservées.

Par ailleurs, suite à des tests, il a été nécessaire d'ajouter une attente entre le téléchargement de deux images car cela posait des problèmes de corruption.

# b. Analyse d'image

L'analyse des images repose sur plusieurs critères. En effet, grâce à la bibliothèque Exiv2, de multiples informations sont extraites des métadonnées de l'image. Le format de fichier ainsi que la taille permettent d'avoir des informations sur la qualité des images stockées dans notre base de données. De plus, dans le cadre

d'une thématique d'image d'appareil photo, il est possible de retrouver le modèle ainsi que la marque de l'appareil.

Finalement la date d'ajout d'image et son statut (image petite, moyenne ou grande) sont encore d'autres informations extraites des images.

## c. Création des tags d'image

Toutes les informations précédemment mentionnées, sont ensuite associées à chaque image. Le tout permet la création d'une base de données d'image référencées avec comme critères : le nom, le format, la taille, la date de capture, la marque et le modèle de l'appareil photo, l'orientation d'image et ensuite une catégorie spéciale intitulée tags.

Enfin depuis la page wikimedia de chaque image sont récupérés les catégories de l'image qu'on transmet en tags.

# II. L'utilisateur et ses recommandations:

#### a. Préférences de l'utilisateur

Un algorithme aléatoire permet de désigner un nombre réduit d'image de la base de données comme appréciées par l'utilisateur.

Le défaut principal de cette méthode est le manque de cohérence entre toutes les images portant le tag "J'aime".

Une possibilité d'amélioration du code serait d'intégrer un système de gestion d'utilisateur qui conserverait les informations pour chaque user différent.

## b. Système de recommandation

Le système de recommandation est fondé sur le décompte des tags associés aux images aimées par l'utilisateur.

Le processus permet de trouver les images ayant le plus de tags en commun avec les Tags les plus aimés par l'utilisateur et de proposer les images en retour à l'utilisateur.

En premier lieu, les images comprenant les trois tags en commun sont proposées puis celles n'en ayant que deux et enfin les images les moins susceptibles de plaire à l'utilisateur sont celles qui n'ont qu'un seul tag voir aucun en commun.

## III. <u>Visualisation des données:</u>

#### a. Base de données

Pour vérifier le contenu de la base de données, un affichage du contenu du JSON et des dictionnaires. Il est ainsi possible de garder une trace de l'évolution de notre base de données.

On comptabilise dans des dictionnaires les différentes années de création des images, modèle d'appareil photo, la taille ainsi que l'orientation de l'image.

#### b. Choix utilisateur

De même, la création de graphique pour référencer les préférences de l'utilisateur permet une meilleure compréhension du profil de ce dernier.

Il devient alors très aisé d'étudier les préférences de notre utilisateur, les tags qui ont le plus de chance de le faire aimer une image. On peut aussi observer le volume d'images issues de la base de données que l'utilisateur n'a pas encore vu et qu'il pourrait apprécier.

# IV. <u>Tests des fonctionnalités:</u>

Tout au long de ce projet, une importance toute particulière a été donnée à la possibilité de vérifier le bon fonctionnement des fonctions à chaque étape. En particulier, il est possible de remarquer la présence d'input d'utilisateur dans la fonction de téléchargement d'image pour la création de la base de données. En effet, ils permettent d'apporter de la souplesse à la fonction. Les deux input ont pour vocation de déterminer la thématique des images et de choisir la taille de la base de données (le nombre total d'images).

Il en va de même dans la suite du code, bien que des input aient été remplacés par des valeurs fixées dans le code.

Par ailleurs, lors de la phase d'attribution des tags, une option est possible pour saisir manuellement des tags pour chaque image. Cette dernière est désactivée actuellement (commentée) pour permettre l'automatisation du processus. De plus, pour tester le système de recommandation un certain nombre de critères sont à respecter. Il est primordial de demander un nombre élevé d'images sur une thématique où la probabilité d'avoir des catégories identiques est élevée. On pourra

prendre par exemple une centaine d'images sur le thème Pizza avec une trentaine d'images aimées par l'utilisateur.

# **Conclusion:**

La réalisation de ce projet a permis d'aborder l'ensemble des thématiques vues en cours ainsi que les algorithmes étudiés en travaux pratiques.

En effet, à partir d'une récolte automatisée d'images provenant d'un site internet et d'un processus d'étiquetage autonome, il a été possible d'accéder à de nouvelles informations.

Ces données permettent ensuite une compréhension plus globale de ce qui peut plaire à un utilisateur et donc par la suite lui fournir plus de contenu adapté, thématique très ancrée dans notre actualité des réseaux sociaux. Enfin, posséder des données en soi n'est pas suffisant. Ce projet a permis la manipulation de graphique et la visualisation des données pour les rendre plus accessibles et compréhensibles.

# Bibliographie et Annexes:

## **Bibliography**

D4N, & Tbeu. Img metadata tools. www.exiv2.org/tags.html

Richardson, L. BS4. www.crummy.com/software/BeautifulSoup/bs4/doc/

Samuel, J. Data Mining. https://link.infini.fr/johnsamueldatam

#### **Annexe**



